

对水下图像增强神经网络 Water-Net 的复现

付可以

摘要

由于水下的吸收和散射效应，正常拍摄的水下图像会受到模糊效果、低对比度和灰显颜色的影响。目前对于地面上的模糊、失真图像来说，已经开发了许多用于图像视觉质量的增强算法，尤其是近年来深度学习的不断发展，大量研究人员利用神经网络来对图像进行增强、恢复。但不幸的是，目前对于水下图像这种特殊的情况来说，由于这些已有的针对陆地上图像的神经网络没有考虑水的强吸收和散射效应，传统的去雾算法用于处理这些模糊程度和色差多变的图像时效果欠佳，都几乎不能用于水下图像的增。这一方面是水下图像噪声较为复杂，不同的水域拍摄到的图像差距明显；另一方面来说，暂未有针对性的水下图像及其参考图像的对应数据集，神经网络的训练都无法构建。本文根据论文 An Underwater Image Enhancement Benchmark Dataset and Beyond^[1]，对作者收集整理用于水下图像增强的数据集 UIEB 进行评估，对文中构建的神经网络 Water-Net 进行复现；同时，本文还复现了一些常见的图像增强算法如 CLAHE、直方均衡化、ACE 等；最后复现经典水下图像评估算法 UIEB 和 UCIQE 并对一般水下图像经过一般图像增强算法和 Water-Net 后的增强结果进行评估比较。

关键词：深度学习；图像增强；图像恢复；水下图像评估；水下图像处理

1 引言

在过去几年中，水下图像增强在图像处理和水下视觉中都引起了相当大的关注。由于复杂的水下环境和光照条件，增强水下图像是一个具有挑战性的任务。通常，水下图像会因波长相关的吸收和散射（包括前向散射和后向散射）而退化。这些不利影响降低了可见度和对比度，甚至引入了彩色投影，因此也限制了水下图像和视频在水下考古、海缆检修、水下机器人等方面的发展^[2]。为了解决这个问题，早期的方法依赖于多个水下图像或偏振滤波器，而最近的算法通过仅使用来自单个图像的信息来处理这个问题^[3]。尽管进行了大量的工作，但由于缺乏公开可用的真实世界水下图像数据集，水下图像增强算法的全面研究和深入分析在很大程度上仍不能令人满意。

此外，对于不同的水类型，几乎不可能同时拍摄真实的水下场景和相应的参考图像。由于缺乏足够和有效的训练数据，基于深度学习的水下图像增强算法都难以实现。而本文中作者自己通过研究实验收集整理了一批效果可以的水下拍摄图像及其真是图像的数据集，这为水下图像增强算法提供了定性和定量的基准。

目前，我的导师准备进行水下机器人的相关研究，在暑期要求我阅读了视觉 slam 相关的书籍以及参加了第六届无人大会水域无人系统的线上会议后，我从中了解到当前水下机器人 ROV 特别是水下无人机器人 AUV 的运动控制大多必须基于良好的视觉定位。但由于水下环境中相机图像在颜色、画质等方面存在较大的失真，这就需要机器人前端视觉里程计所拍摄的水下低特征图像能够经过一定的图像增强技术，得到高特征图像来使后端的处理程序能够更好的运行，因此我选择了这篇针对水下图像增强的文章。与此同时，在李清泉书籍的指导安排下，我的导师和建规学院的汪老师在主导推进

“高空气球”的项目，并将高空气球图像处理与目标识别这块的任务交给我进行探索学习，在经过相关了解后，我发现高空(平流层)拍摄到的图像与水下图像类似，存在如云朵遮盖、光照条件的变化、地物边界的多样性等问题，这使得这些高空图像的特征也很差，大量的图片不能直接用来进行模型训练。基于以上两点，这篇水下图像处理以及深度学习图像增强的文章十分适合目前我的复现学习。

通过对这篇论文的阅读、理解与算法复现，在学习神经网络与图像处理相关知识的同时，也希望能够真正的帮助解决我目前项目上遇到的问题，为未来进行高空图像处理神经网络的搭建打好了基础。

2 相关工作

2.1 传统的水下图像增强方法

近年来，由于水下探索需求的不断深化，已经有越来越多的人开始对水下图像特征和增强的研究。水下图像增强作为提高记录图像视觉质量的一个不可或缺的步骤，已经提出了多种方法，主要可分为四类：基于信息补充的方法、基于非物理模型的方法、基于物理模型的方法和基于数据驱动的方法。

2.1.1 基于信息补充的方法

在早期阶段，利用来自多个图像或专用硬件设备（例如偏振滤波、距离门控成像和荧光成像）的补充信息来提高水下图像的可视性^[4]。与基于补充信息的方法相比，单一水下图像增强方法更适用于动态场景等具有挑战性的情况。

2.1.2 基于非物理模型的方法

基于非物理模型的方法旨在修改图像像素值以提高视觉质量。例如通过对图像 RGB 颜色空间或 HSV 颜色空间中进行像素的动态拉伸，以此来提高水下图像的对比度和饱和度。其中特别的，Ancuti 等人提出了一种混合对比度增强图像和颜色校正图像的多尺度融合水下图像增强方法^[5]；Fu 提出了一种基于视网膜的水下图像增强方法，包括颜色校正、图层分解和增强^[6]。

2.1.3 基于物理模型的方法

基于物理模型的方法将水下图像的增强视为一个逆问题，也就是通过构建水下光折射、水浪波纹等的物理模型，对拍摄到的图像进行逆向还原。这些方法通常遵循相同的流程：1) 建立退化的物理模型；2) 估计未知模型参数；3) 解决这个逆问题。其中特别的是基于何凯明构建的暗通道先验算法^[7]；也有研究^[8]将暗通道先验与波长补偿相关算法相结合，实现水下图像的恢复，并且基于水下图像中红色通道信息的不可靠性，提出了水下暗通道先验(UDCP)。

2.1.4 基于数据驱动的方法

近期，深度学习在解决低层次视觉问题方面取得了显著进展。基于数据驱动的方法就是通过构建相关神经网络，利用大量水下图像数据进行训练使模型有一个较好的效果。现有的网络大都是单输入和单输出的，这种方法可以使用合成的退化图像对和高质量的对应图像进行训练。然而，水下成像模

型取决于特定的场景和光照条件，甚至与温度和浊度有关^[9]。因此简单的用拍摄图像作为输入、参考图像作为输出得到的效果往往不尽如人意，无法满足真实水下的繁杂情况。

2.2 水下图像的评估指标

2.2.1 全参考指标

现代应用中，利用原始图像的全部信息，计算失真图像与原始图像间的误差，并通过综合误差进而获取对失真图像质量综合评价的方法，称之为全参考型图像质量评价方法。全参考图像质量评价需要原始图像，经过数十年的开展已经形成了较为完整的理论体系和成熟的评价框架。待评价的图像信号的质量可以通过与原图像的信号做比照之后所获取的误差信号来分析，图像质量的下降与误差信号的强弱有关。具有代表性的全参考指标有均方差 MSE、峰值信噪比 PSNR、结构相似性 SSIM^[10]。

2.2.2 非参考指标

图像的无参考评价是目前图像客观质量评价的研究难点和热点。这种评价方法无须任何原始参考图像信息，仅利用图像自身的特征进行质量评估，因此非常灵活，可以广泛应用于各种场景。特别是针对水下图像这种很难找到与失真图像对应的真是图像的情况，采用非参考图像质量评价指标，如图像熵、可见边缘^[11]和动态范围无关的图像质量评价^[12]是更好的。

2.2.3 其他一些指标

除开前面的全参考和非参考指标，还可以通过判断特征点数、边缘检测等方法。本文种作者引用了两篇针对水下图像评估算法的论文，也就是 UCIQE^[13]和 UIQM^[14]。UCIQE 首先量化不均匀的颜色浇铸、模糊和低对比度，然后以线性方式组合这三个组件；UIQM 包括三个属性度量：色彩度量、清晰度度量和对比度度量。这两种方法都不只是对单一特征进行评估，而是针对水下图像失真特有的水对光的吸收、普遍呈蓝绿色等特征进行了融合分析评估。

2.3 UIEB 数据集的收集整理

水下图像增强研究中存在的主要问题是缺乏具有参考对照图像的大规模真实世界水下图像数据集。因此，为了说明构建的 UIEB 数据集相较来说更为优秀，这里详细说明了数据集构建的方法：

2.3.1 数据收集

水下图像采集的目标有三个：1) 水下场景的多样性，质量退化不同特征，应涵盖广泛的图像内容；2) 水下图像量要大；3) 提供相应的高质量参考图像，使成对的图像能够进行公平的图像质量评价和端到端学习。为了实现前两个，UIEB 通过对 google、youtube 和作者自己拍摄的水下等 10000 多张图像进行了收集、分类、整理得到了 950 张图像，其中包含了大范围的图像分辨率，跨越了不同的场景/主要物体类别。

2.3.2 构建参考图像

作者采用 ACE、UDCP、直方图先验等十二种常见的图像增强算法，这些算法包含了基于回归的、基于视网膜的等。使用这些算法对上面收集得到的 950 张图像进行增强，得到 12*950 张增强结果。然后邀请了 50 位志愿者（25 名志愿者具有图像处理经验；25 名无相关经验的志愿者）对同一监视器下每个原始水下图像的 12 个增强结果进行两两比较。也就是每次随机从一组中选两张给志愿者，志愿者选择自己认为更好的，然后从剩下的里面选一张再次进行比较，直到比较十一次选出最终结果。之后，如果所选参考图像的不满意票数超过半数，则将其对应的原始水下图像作为挑战图像处理，并丢弃参考图像。通过以上步骤，就得到了最终 UIEB 数据集中的 890 张水下图像。

2.3.3 对 UIEB 进行评估

定性评估：从 UEIB 中中绿色和蓝色图像、向下看图像、向前看图像、低反向散射场景、高反向散射选择了五个场景对应的图像；然后用 9 种不同的增强方法对其进行增强；最后将这些增强后的图像与志愿者选出的参考图像进行对比得出结论——①基于视网膜的方法很好地消除了颜色偏差；②基于融合的、基于视网膜的和直方图先验显著地消除了水下图像上的雾度影响；③低反向散射场景（相机和场景之间的短距离），反向散射的影响相对容易消除，高反向散射（长距离）显著降低了水下图像的视觉质量。

定量评估：使用全参考指标 MSE、PSNR、SSIM，非参考指标 UIQM、UCIQE 这两类对上面得到的增强图像和参考图像进行评估，得到的结果显示由志愿者选择的参考图像在平均水平都比普通的增强要优。

2.4 水下图像增强模型 Water-Net

尽管水下图像增强方法取得了显著的进展，但由于缺乏有效的训练数据和设计良好的网络架构，基于深度学习的水下图像增强模型在推广方面仍落后于传统的最先进方法。利用 UIEB，作者提出了一个基于融合的^[7]用于水下图像增强的 CNN 模型 Water-Net。

Water-Net 是一个门控融合网络，它将输入与其他增强算法预测的置信图融合，以实现增强的结果。首先通过特征变换单元（FTU）将输入转换为细化输入，然后预测置信图，最后通过融合细化的输入和相应的置信图来实现增强的结果。

3 本文方法概述

3.1 水下图像评估模块

阅读了水下图像相关的一些论文：基于红色暗通道先验和逆滤波的水下图像复原^[15]、基于亮通道色彩补偿与融合的水下图像增强^[16]、Underwater image enhancement method based on adaptive attenuation-curve prior^[17] 等，并根据这些论文收集整理了水下图像存在的一些问题、这些问题产生的原因、已有的针对这些问题的解决方法、针对水下图像失真的图像增强技术等；和两篇关于水下图像评估算法的论文：Human-Visual-System-Inspired Underwater Image Quality Measures^[14] 和 An Underwater Color Image Quality Evaluation Metric，并根据这两篇论文对 UIEB 和 UCIQE 算法利用 python 进行编写复现。

3.2 神经网络模块

根据作者论文中提出的神经网络模型，使用 tensorflow 框架对该网络的八层主网络和三层次网络 FTU 进行了复现，并分别编写了对数据集的训练和自己图像的测试文件。

3.3 数据预处理模块

根据水下图像退化的特点，分别对水下图像采用白平衡 (WB)、直方图均衡化 (HE) 和伽马校正 (GC) 算法，生成三种输入。而我通过对其他一些论文的阅读，在了解了水下图像退化的特点及其相关处理方法后，对作者构建网络的输入进行了修改：将普通的白平衡 WB 改为了自动白平衡算法 WBP，并将灰度直方图均衡化 HE 改为了限制对比度自适应直方图均衡化算法 CLAHE；具体来说，WBP 算法用于校正颜色投射，而 CLAHE 和 GC 算法分别用于提高对比度和淡化暗区。

3.4 测试部分

我使用 UIEB 数据集中的 800 张图像对网络进行了训练，然后构建了两个测试集：1、剩下的 90 张和作者前面提供的富有挑战性的 60 张一共 150 张图像；2、RUIE 水下图像数据集。使用该网络以及其他一些算法对这两个测试集进行增强，最后通过 UIQM 和 UCIQE 打分评估进行定量分析以及通过与其他一些增强算法效果比较进行定性分析。

4 复现细节

4.1 UIQM 和 UCIQE 的复现

4.1.1 UIQM 的复现

UIQM 包括水下图像色彩度量 (UICM)、水下图像清晰度度量 (UISM) 和水下图像对比度度量 (UIConM) 三种度量。选择这些属性不仅是因为它们容易因水介质的物理特性而变化，比如吸收导致颜色饱和度降低和颜色褪色，散射导致模糊和对比度退化，还因为 HVS 对颜色、边缘结构和相对对比度的变化非常敏感。也就是说，这些图像属性的变化会产生完全不同的人眼视觉感受。

1、UICM：

由于 HVS 捕捉对手颜色平面上的颜色，因此 UQIM 在 UICM 中使用与色度 RG 和 YB 相关的两个对手色分量：

$$RG = R - G \quad (1)$$

$$YB = \frac{R + G}{2} - B \quad (2)$$

水下图像通常有很大的噪声，UICM 采用非对称 alpha 裁剪统计值代替常规统计值来测量水下图像的彩色度：

$$\mu_{\alpha, RG} = \frac{1}{K - T_{\alpha L} - T_{\alpha R}} \sum_{i=T_{\alpha L}+1}^{K-T_{\alpha R}} Intensity_{RG,i} \quad (3)$$

其中 $K = M \times N$ ，也就是图像的分辨率； $T_{\alpha L}$ 是 $\alpha_L K$ 的上取整， $T_{\alpha R}$ 是 $\alpha_R K$ 的下取整； α_L 和 α_R 是根据具体情况设定的。

直观来说，较大的方差对应较大的动态范围，这里针对像素间的差距采用了二阶统计方差 σ^2 ：

$$\sigma_{RG}^2 = \frac{1}{N} \sum_{p=1}^N (Intensity_{RG,p} - \mu_{\alpha, RG})^2 \quad (4)$$

最后，通过线性方式将上述指标进行集合，得到用于测量水下图像色彩的整体色彩度量， μ 越接近 0 则平衡越好， σ^2 越大色彩对比度越好：

$$UICM = -0.0268\sqrt{\mu_{\alpha, RG}^2 + \mu_{\alpha, YB}^2} + 0.1586\sqrt{\sigma_{\alpha, RG}^2 + \sigma_{\alpha, YB}^2} \quad (5)$$

2、UISM:

对于在水下拍摄的图像，由于前向散射，会出现严重的模糊，这里采用计算锐度的方法来评估。锐度是一种用来反映图像平面清晰度和图像边缘锐利程度的指标，UISM 采用 EME 增强度量估计的方式，首先 Sobel 边缘检测器首先应用于每个 RGB 颜色分量。然后将得到的边缘图与原始图像相乘以获得灰度边缘图，以此来只保留原始水下图像边缘上的像素。

相关公式如下：

$$UISM = \sum_{c=1}^3 \lambda_c EME(grayscaleedge_c) \quad (6)$$

$$EME = \frac{2}{k_1 k_2} \sum_{l=1}^{k_1} \sum_{k=1}^{k_2} \log \left(\frac{I_{max,k,l}}{I_{min,k,l}} \right) \quad (7)$$

图片被分为 $K1*K2$ 个区域（我在实际使用时将其分为 $8*8$ 个区域，之后的算法中也是一样）， \log 中的分式是每个区域中亮度最大与最小值的比值，即对比度，算出 RGB 三通道的 EME，随后带入到 UIISM 公式中，公式中的 λ_c 中是根据红色、绿色和蓝色通道的相对视觉来决定的，UIISM 种使用 $\lambda_R=0.299$, $\lambda_G=0.587$, $\lambda_B=0.114$ 。

3、UIConM:

对于水下图像，对比度下降通常由后向散射引起的。在 UIQM 中，通过对强度图像应用 logAMEE 度量来测量对比度：

$$UIConM = \log AMEE(Intensity) \quad (8)$$

$$\log AMEE = \frac{1}{k_1 k_2} \otimes \sum_{l=1}^{k_1} \sum_{k=1}^{k_2} \frac{I_{max,k,l} \ominus I_{min,k,l}}{I_{max,k,l} \oplus I_{min,k,l}} \times \log \left(\frac{I_{max,k,l} \ominus I_{min,k,l}}{I_{max,k,l} \oplus I_{min,k,l}} \right) \quad (9)$$

与前面的 UIISM 一样，将图片分为了 $K1*K2$ 个区域，其中的运算符是克罗内克运算符 (PLIP)，被广泛用于张量计算^[18]。PLIP 运算提供了与人类视觉感知一致的非线性表示，也用于 logAMEE 公式。实际上，水下的照明条件通常很差，这种情况下 logAMEE 是首选，因为 log 和 PLIP 操作更加强调低亮度区域。对于 PLIP 的详细计算方式我在此不过多赘述，上面使用到的相关计算公式如下：

$$\begin{aligned} \alpha \oplus b &= \alpha + b - \frac{\alpha b}{\gamma(M)} \\ \alpha \ominus b &= k(M) \frac{\alpha - b}{k(M) - b} \\ c \otimes \alpha &= \gamma(M) - \gamma(M) \left(1 - \frac{\alpha}{\gamma(M)} \right)^c \end{aligned}$$

4、UIQM:

大量研究已经证明水下图像可以建模为吸收和散射分量的线性叠加，因此 UIQM 使用线性叠加模型来生成整体水下图像质量度量也是合理的。总体水下图像质量度量如下式：

$$UIQM = c_1 \times UICM + c_2 \times UISM + c_3 \times UIConM \quad (10)$$

UIQM 有三个参数, c_1 、 c_2 和 c_3 , 它们的选择取决于具体情况。在 UIEB 的论文中作者没有明确指明三个参数使用的值是多少, 这里我使用 UIQM 论文种测试时使用的参数: $c_1=0.0282$, $c_2=0.2953$, $c_3=3.5753$ 。

4.1.2 UCIQE 的复现

UCIQE 是一种基于 CIELab 色度、对比度和饱和度测量的水下彩色图像质量评估度量。通过色度、对比度和饱和度这三种质量度量, 它可以比其他自然彩色图像度量更准确地测量水下环境中类似内容的相对退化量。由于该评估算法比较简单, 这里直接给出最终公式:

$$UCIQE = c_1 \times \sigma_c + c_2 \times con_l + c_3 \times \mu_s \quad (11)$$

其中 σ_c 是色度的标准偏差, con_l 是亮度的对比度, μ_s 是饱和度的平均值。这些特征量的相关计算过程在 UIEB 中已经详细说明, 这里不再过多介绍。UCIQE 的计算过程为: (1) 转换到 CIELab space 进行特征提取 (2) 计算三个特征量 (3) 参数权重拟合

4.2 Water-Net 的复现

根据 Water-Net 的网络结构图, 我使用 tensorflow 框架对该神经网络进行了搭建。

4.2.1 基础部件和工具的实现

1、定义实现该神经网络中的基础部件——二维卷积在 ops.py 中, 我定义了一个 conv2d 函数, 通过输入数据数组、输入通道数、输出通道数、卷积核的长宽、卷积的步长, 使用 tensorflow 进行卷积计算, 并将结果数组返回回去。特别的, 为了简便实现, 网络中使用 tensorflow 自带的 relu 和 sigmoid 激活函数。

2、图像读取在进行图像的训练时, 需要读取原始、参考和经过三种不同增强后的五个文件夹中的图像, 而这些图像的读取都是以文件夹为单位的, 也就是只用在标志 flags 处将指定的文件夹路径输入即可。因此为了在训练过程中避免重复实现一个文件夹中所有图像的读取工作, 我在 utils.py 文件中编写了一个专门用于各种格式图像的读取函数, 该函数以 tensorflow 的 session 和图像文件夹路径问输入参数, 返回该文件夹中所有图像。

3、训练参数的读取与存储在进行模型训练的过程中, 难免遇到死机、程序中断等突发状况, 导致训练了许久的参数丢失, 浪费大量时间。因此我再模型训练的模型 TNN 类中写了两个类函数 load 和 save, 这两个函数使用 os 包对参数文件进行读写。在网络训练中, 每训练完一个批次就对当前得到的参数进行保存, 并且在下次开始时自动接着上一次的进行。

4.2.2 核心网络的实现

由于复杂的水下环境和照明条件, 没有一种算法适用于所有类型的水下图像。但总的来说, 得益于多个预处理操作和融合策略得出的输入, 基于融合的方法可以取得较为不错的结果。在作者拟议的 Water-Net 中, 也采用了这种融合的方式。该网络基于水下图像退化的特点, 通过分别对水下图像应用白平衡 (WB)、直方图均衡 (HE) 和伽马校正 (GC) 算法来生成三个输入。具体而言, WB 算法

用于校正颜色投射，而 HE 和 GC 算法分别旨在提高对比度和亮暗区域。这里，通过相关论文的阅读与调研，我将 HE 修改为了更为优秀的 CLAHE（限制对比度自适应直方图均衡化），并更换了普通的 WB，使用的是经过 WBP 后的图像。

具体的网络结构如图 1 所示，主要包含两个网络结构，一个是具有八层卷积的主网络，这个网络以原始图像、经过 WB 后的图像、经过 CLAHE 后的图像、经过 GC 后的图像作为输入，经过这八层卷积的训练后，再由一个 sigmoid 得到四维输出数组 (16, 112, 112, 3)；另一个是 FTU，该网络只包含三个卷积，以原始图像和一种方法增强后的图像作为输入，然后通过一个 Relu 函数得到一个四维输出数组 (16, 112, 112, 1)。最后，将主网络输出图像按通道进行切分并将其与 FTU 得到的三个置信图进行结合（分别点成后然后相加）后输出。

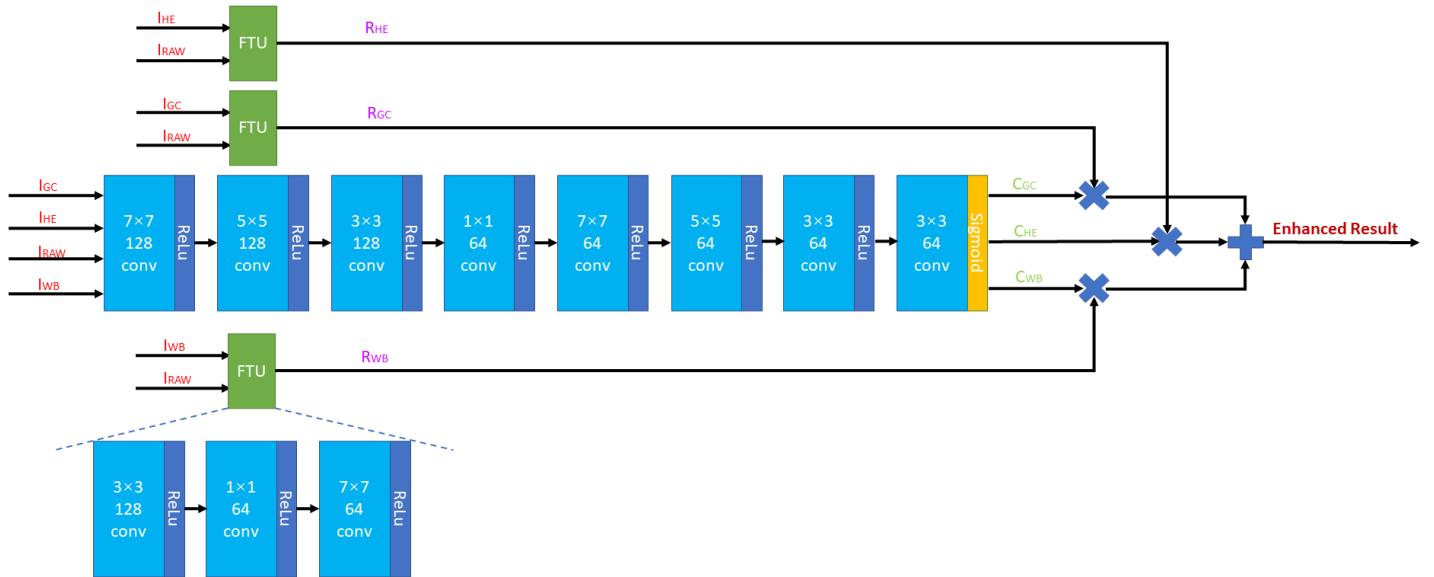


图 1: Water-Net 网络结构

4.2.3 测试和训练的实现

作者在开源代码中只提供了用于测试的 python 代码文件，而且经过我的测试，该测试文件由于使用了 tensorflow 内部函数，必须保证所有图像输入为 720*1280，而一般的图像尺寸是无法完全把握的。也就是说，当一个用户仅仅想要使用该网络进行增强操作前，需要实现改变尺寸和对原始图片进行三种增强预处理，过于麻烦。

因此针对测试文件，我经过对代码的熟读分析，进行了相应的修改，使用户输入任意尺寸的图片都可以进行增强；而且我将图像的预处理也就是对原始图像进行 CLAHE、WB、GC 的处理全都集成到了测试函数内部，直接调用 opencv 内集成的算法实现。最终，用户只需要输入一张原始图像，测试网络会调用相关函数自动生成三种增强后的图像，然后自动将这些图像封装并分别丢到上述的主网络和 FTU 网络中进行训练，并将最终结果保存到指定文件夹中。图像测试(增强)流程图如图 2 所示：



图 2: 图像测试(增强)流程图

而对于训练部分，我则是使用 tensorflow 框架进行了编写。首先我为了使在我笔记本这种低配置环境也可以进行正常快速的训练，进行了两个预处理操作：1、对 UIEB 数据集的原始和参考图像均进行缩放，将尺寸全部修改为 112*112，以使进行训练时可以将 batchsize 设置得更大的同时显存还够用，能够同时训练更多的图像，加快训练速度；2、为了使训练网络能够完整的放入我笔记本的显存中，以及使训练时间更短，我在此不像上面测试部分代码那样在网络内部集成三种增强图像的生成方法，而是通过编写了一些函数文件对 UIEB 整个原始数据集进行预处理，在训练之前就生成增强图像。

此外，为了进一步加速训练，使得模型收敛更快，达到更好的效果，我在网上下载了 VGG-19 的模型及训练好的参数，将其用作训练网络中的预训练模型。具体就是图像经过 Water-Net 训练后，再经过 VGG-19 网络的训练，这样以来该网络模型的效果可以得到较大提升。

最后，我还增加了验证集测试部分，在进行网络模型训练时，当训练完后，会自动读取验证集中的图像数据进行验证。需要注意的是，由于训练部分与测试部分是分开的，且并未像测试部分那样将图像预处理集成到训练文件中，所以对这些验证集也必须像训练集一样进行 resize 和三种增强预处理操作。

训练流程图如图 3 所示：

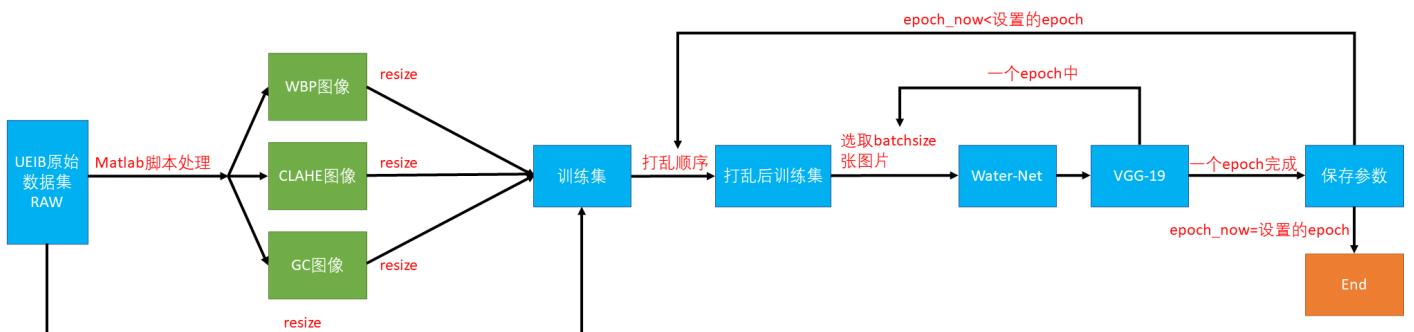


图 3: Water-Net 训练流程图

最后，使用 UIEB 数据集对 Water-Net 进行训练后，就可以使用训练好的模型参数对自己的图像进行增强操作。我在此选择了七张尺寸、特征均不相同的水下图像进行测试，其变换过程如下图 4 所示：

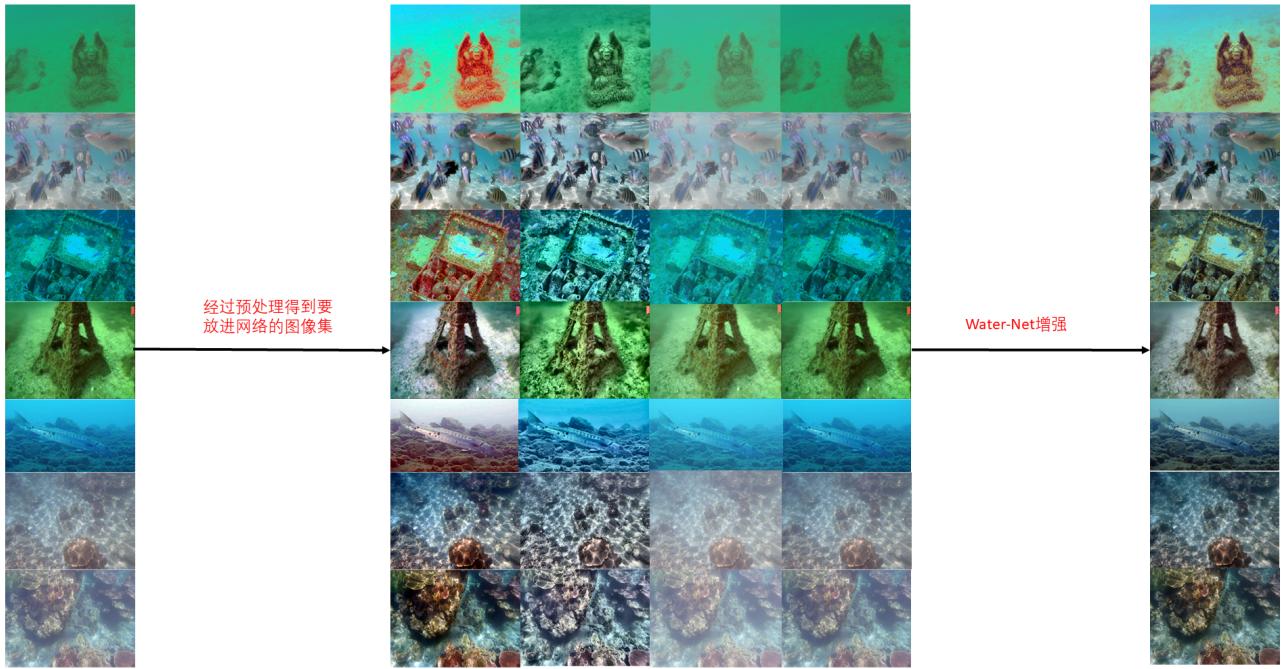


图 4: Water-Net 训练流程图

4.3 预处理算法的实现

此部分主要是对上述模型训练部分的预处理操作进行实现，对训练图像的预处理主要包括两个部分：实现对图像尺寸的修改，可以直接用 python 的 `resize` 函数实现，这里不再过多说明；实现对原始图像的 WBP、CLAHE、GC 增强操作，下面我会详细说明这些基础增强算法的思路方法以及如何用代码进行实现。

4.3.1 优化后的白平衡算法

所谓白平衡，就是对白色点的还原，也就是如果原始场景中的某些像素点应该是白色的（即 $R=G=B=255$ ），但是由于图像存在色偏，这些点的 R、G、B 三个分量的值不再保持相同。那么就可以通过调整这三个颜色分量的值，使之达到平衡，由此获得对整幅图像的彩色平衡映射关系，通过该映射关系对整幅图像进行处理，即可达到彩色平衡的目的。

作者在实验中用到的是哪种白平衡算法并没有明确说明，但一般来说白平衡算法也就是对普通的 RGB 色彩空间进行调整。而我在实现过程中更换成了效果更佳了自动白平衡算法，而因此我对现有的五种自动白平衡算法进行了测试评估，使用一张水下图像进行了测试，原图及增强后图像如图 5 所示：



图 5: 自动白平衡算法对比，依次是原图、均衡白平衡法、完美反射法、灰度世界假设法、基于图像分析的偏色检测及颜色校正方法、动态阈值算法

显然动态阈值算法效果最优，因此我最后选择了动态阈值白平衡算法。该算法不是仅仅对 RGB 色彩空间进行分析处理，而是通过将 RGB 变化到 YCrCb 颜色空间进行分析来确定白点，且选择参考白点的阈值是动态变化的。算法流程如下：

- 1、把图像从 RGB 空间转换到 YCrCb 空间
- 2、把图像分成宽高比为 4:3 的块
- 3、对每个块，分别计算 Cr, Cb 的平均值 Mr, Mb
- 4、对每个块，根据 Mr, Mb，用下面公式分别计算 Cr, Cb 的方差 Dr, Db
- 5、判定每个块的近白区域，设一个“参考白色点”的亮度矩阵 RL。若符合判别式，则作为“参考白色点”，并把该点的亮度值赋给 RL(i,j); 若不符合，则该点的 RL(i,j) 值为 0
- 6、选取参考“参考白色点”中最大的百分之 10 的亮度 (Y 分量) 值，并选取其中的最小值 Lumin
- 7、调整 RL，若 $RL(i,j) < Lumin$, $RL(i,j)=0$; 否则， $RL(i,j)=1$
- 8、分别把 R, G, B 与 RL 相乘，得到 R2, G2, B2。分别计算 R2, G2, B2 的平均值，Rav, Gav, Bav
- 9、得到调整增益： $Y_{max}=\text{double}(\max(\max(Y)))/5$; $R_{gain}=Y_{max}/Rav$; $G_{gain}=Y_{max}/Gav$; $B_{gain}=Y_{max}/Bav$
- 10、调整原图像： $R_o=R \cdot R_{gain}$; $G_o=G \cdot G_{gain}$; $B_o=B \cdot B_{gain}$

4.3.2 CLAHE

作者在文中说明其使用的是传统的直方均衡化算法 HE，而经过我的查阅整理，发现 HE 算法得到的结果会存在一些问题，主要包括：1) 部分区域由于对比度增强过大，成为噪点；2) 一些区域调整后变得更暗/更亮，丢失细节信息。

在 HE 的基础上，通过计算图像每一个显著区域的直方图，来重新分布图像的亮度值，就得到了自适应直方均衡化算法 AHE，它更适合于用来改善图像的局部对比度，以及增强图像边缘信息，利于

分割。但是，AHE 有一个缺陷，就是他在增强对比度的同时也会增强图像同质（均匀）区域的噪声，因此作为 AHE 的改进，CLAHE 可以有效降低这种噪声的增强。

在自适应直方图均衡算法的基础上，加上阈值，用来限制对比度，达到削弱噪点放大问题的效果，并且使用线性插值/双线性插值的方法来优化块与块之间过渡问题，使图像看起来更加和谐。限制对比度的做法，就是在使用常规做法得到常规的直方图后，会将直方图中统计的灰度值与我们设定的阈值进行对比，对于超过阈值的部分，我们会将这部分均匀地分布在每一个不同的灰度值下面。

CLAHE 的结果相对于 HE 的结果，不会出现结果像素相比于原图因调整得更亮/更暗而丢失了细节的情况，且局部对比度会更强。



图 6：直方均衡化算法对比，依次是原图、普通直方均衡化 HE——均衡化亮度分量、普通直方均衡化 HE——增饱和度、自适应直方均衡化 AHE、限制对比度自适应直方图均衡算法 CLAHE、全局化限制对比度自适应直方图均衡算法

如图 6 所示是我对一张水下图像分别进行五种直方均衡化后的结果，通过肉眼我无法看出其中的优劣。在网络中使用 HE/CLAHE 图像是为了提高原始图像的对比度，因此使用了 UCIQE 中计算的亮度的对比度平均值分别对六张图像的对比度进行了评估，结果如表 1 所示：

增强方法	RAW	HE-1	HE-2	AHE	CLAHE-1	CLAHE-2
conl 对比度	0.4586	0.9218	0.9156	0.8577	0.7487	0.9384

表 1：经过不同直方均衡化后的对比度值

根据评估得到的结果，我最终选择了全局化限制对比度自适应直方均衡算法。也就是将 RGB 图像转换到 YCrCb 空间中，然后将 YCrCb 图像通道分离并对第一个通道即亮度通道进行全局 CLAHE，最后将处理后的通道和没有处理的进行合并再转换回 RGB 图像。

4.3.3 GC

Gamma 校正是对输入图像灰度值进行的非线性操作，使输出图像灰度值与输入图像灰度值呈指数关系，其公式如下：

$$Gamma = K \times E^r = 255 \times E^{\log(p(x,y)/255) \times gamma} \quad (12)$$

其中 gamma 就是参数值，其取值范围在 0.05 到 5 之间。gamma 的值决定了输入图像和输出图像之间的灰度映射方式，即决定了是增强低灰度值区域还是增高灰度值区域：

- gamma>1 时，图像的高灰度区域对比度得到增强，直观效果是一幅偏亮的图变暗了下来。
- gamma<1 时，图像的低灰度区域对比度得到增强，直观效果是一幅偏暗的图变亮了起来。
- gamma=1 时，不改变原图像。

对于水下图像，大多都是偏暗的，所以在此我对小于 1 的参数值从 0.1 一直测试到了 0.9，最后得到 0.7 的效果为最佳，因此选择 gamma=0.7。

4.4 实验环境搭建

本文中的算法复现、网络搭建以及相关数据集的训练均在作者本人的笔记本电脑上完成，相关软硬件配置情况如下：

软件：windows10 系统

- matlab: 9.13.0
- matlab-Image Processing Toolbox: 11.6
- matplotlib: 3.3.4
- opencv: 4.6.0
- numpy: 1.16.6
- PIL: 8.4.0
- tensorflow: 1.15.0
- tensorflow-gpu: 1.15.0
- vgg: 19
- cuda: 10.0
- cudnn: 7.6
- nvidia-driver: 516.94

硬件：小米游戏本 2018

- CPU: Intel(R) Core(TM) i7-8750H CPU @ 2.20GHz 2.21 GHz
- 内存: 16GB——8G 金士顿 DDR4 2666+8G 三星 DDR4 2666
- GPU: NVIDIA GeForce GTX 1050 Ti (4GB 显存)
- 硬盘: 256GB+1TB

4.5 界面分析与使用说明

我已将编写的相关源代码上传到了 GitHub 上，包括预处理、训练、测试以及一些其他的工具函数 python 文件；同时，我也将所用到的相关数据集 UIEB-890、UIEN-challenge、RUIE，以及我训练好的参数文件等上传到了百度网盘上，相关连接可见 github 中的 Readme.md 文件。

如果你仅仅想要使用该网络对水下图像进行增强操作，请按以下步骤操作：

- 1、克隆我的项目到你的本地，并解压缩打开

- 2、通过 Readme.md 文件中提供的路径，下载百度网盘中的 checkpoint 参数压缩文件，并将其解压缩到项目根目录下
- 3、将你需要增强的图像放在一个 test-real 文件夹中
- 4、打开 maintest.py 文件，将 is-train 设置为 false，并根据你的具体路径对 test-datadir 和 sample-dir 进行修改
- 5、运行 python maintest.py，完成后就可以在 sample-dir 看到结果了

如果你需要使用该网络对 UIEB 或你自己的数据集进行训练，相关步骤如下：

- 1、克隆我的项目到你的本地，并解压缩打开
- 2、通过 Readme.md 文件中提供的路径，下载百度网盘中的 vgg-pretrained 参数压缩文件、UIEB-890 数据集，并将其解压缩到合适的地方
- 3、打开 maintrain.py 文件，对参数（训练批次 epoch、批量大小 batch-size、原始图像大小 image-height 和 image-width、参考图像大小 label-height 进而 label-width、学习率）进行修改
- 4、通过我提供的 matlab/python 文件，修改相关参数（如 resize 后的大小、三种增强后的存储路径等），对 UIEB-890 或你自己的数据集进行预处理，得到四个文件夹分别保存 resize 后的原始、WBP、CLAHE、GC，然后将对应的参考图像也做 resize 处理。需要特别注意的是，经过我的测试，由于该网络层数较少且数据集较小，若设置较大的训练批次 epoch 会产生极大的过拟合，这里如果你使用的是 UIEB 进行训练，我建议 epoch 设置为 100 就好。
- 5、将得到的四种不同的图像分别放在根目录的 input-train、input-wb-train、input-ce-train、input-gc-train 和 gt-train【需要注意的是：如果你有验证集，也需要进行同样的处理，并分别放到 input-test、input-wb-test、input-ce-test、input-gc-test-test；如果没有验证集，也需要建立这五个文件夹为空即可】
- 6、运行 python maintrain.py，完成后就可以在 checkpoint/coarse-112 中看到训练得到的参数文件了

5 实验结果分析

随机选择 UIEB 数据集中原始和参考对应的 800 对图像对 Water-Net 进行训练，并将训练得到的参数保存到 checkpoints 文件夹中。

5.1 定性分析

针对水下图像的常见性特征以及相关拍摄角度，在 UIEB 数据集中分别选择了符合绿色、蓝色、蓝绿色这三类颜色特征，低反向散射场景、高反向散射场景这两类模糊特征，向下看、向前看这两类拍摄特征的各一张图像，并采用 Water-Net、暗通道先验 DCP、自动色阶 AL、Histogram Normalization、Retinex-SSR、Retinex-MSR、ACE、Laplus 算子、Log、同态滤波这十种基础图像增强算法进行增强，得到的结果如图 7 到 13：



图 7: 绿色水下图像比较。从左上到右下依次是原始水下图像、DCP 增强图像、AL 增强图像、HN 增强图像、Retinex-SSR 增强图像、Retinex-MSR 增强图像、ACE 增强图像、Laplus 算子增强图像、Log 增强图像、同态滤波增强图像、Water-Net 增强图像、UIEB 参考图像



图 8: 蓝色水下图像比较。从左上到右下依次是原始水下图像、DCP 增强图像、AL 增强图像、HN 增强图像、Retinex-SSR 增强图像、Retinex-MSR 增强图像、ACE 增强图像、Laplus 算子增强图像、Log 增强图像、同态滤波增强图像、Water-Net 增强图像、UIEB 参考图像

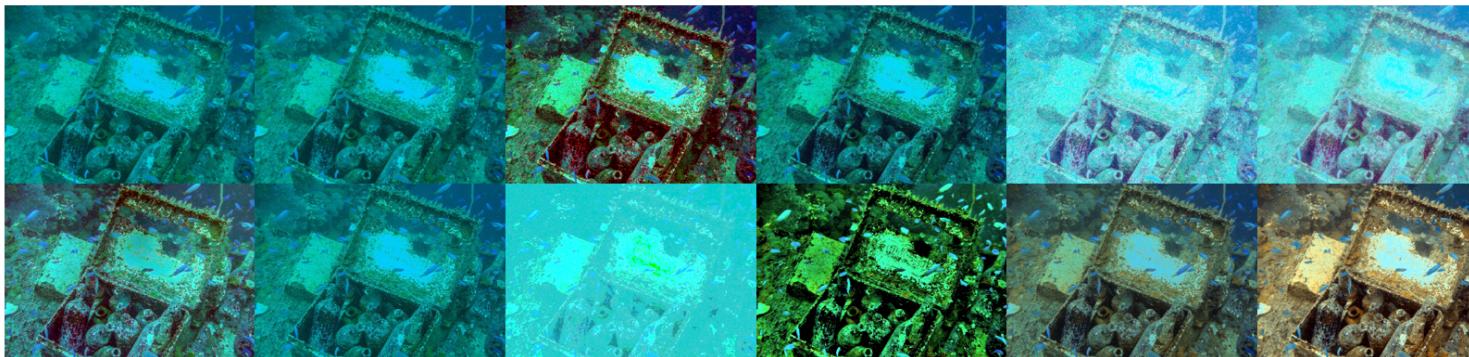


图 9: 蓝绿色水下图像比较。从左上到右下依次是原始水下图像、DCP 增强图像、AL 增强图像、HN 增强图像、Retinex-SSR 增强图像、Retinex-MSR 增强图像、ACE 增强图像、Laplus 算子增强图像、Log 增强图像、同态滤波增强图像、Water-Net 增强图像、UIEB 参考图像



图 10: 低反向散射场景水下图像比较。从左上到右下依次是原始水下图像、DCP 增强图像、AL 增强图像、HN 增强图像、Retinex-SSR 增强图像、Retinex-MSR 增强图像、ACE 增强图像、Laplus 算子增强图像、Log 增强图像、同态滤波增强图像、Water-Net 增强图像、UIEB 参考图像

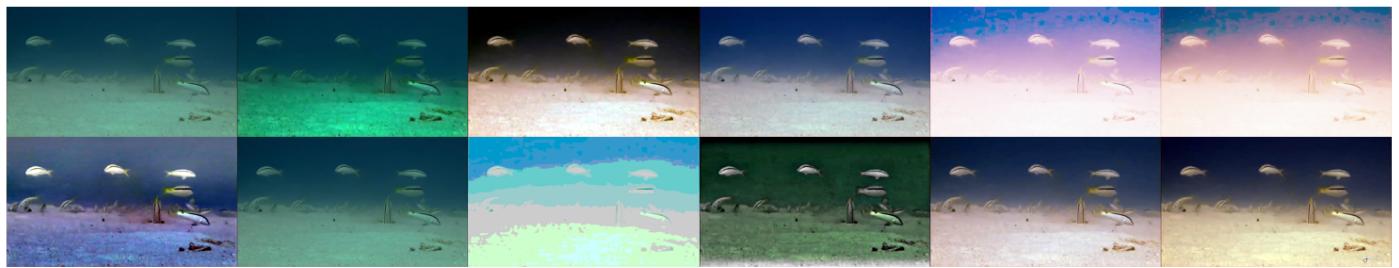


图 11: 高反向散射场景水下图像比较。从左上到右下依次是原始水下图像、DCP 增强图像、AL 增强图像、HN 增强图像、Retinex-SSR 增强图像、Retinex-MSR 增强图像、ACE 增强图像、Laplus 算子增强图像、Log 增强图像、同态滤波增强图像、Water-Net 增强图像、UIEB 参考图像

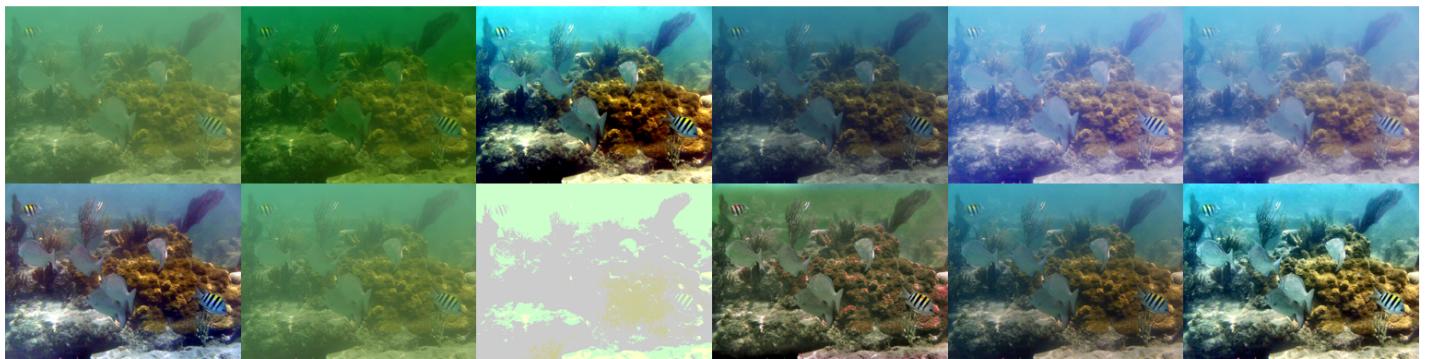


图 12: 前视水下图像比较。从左上到右下依次是原始水下图像、DCP 增强图像、AL 增强图像、HN 增强图像、Retinex-SSR 增强图像、Retinex-MSR 增强图像、ACE 增强图像、Laplus 算子增强图像、Log 增强图像、同态滤波增强图像、Water-Net 增强图像、UIEB 参考图像



图 13: 俯视水下图像比较。从左上到右下依次是原始水下图像、DCP 增强图像、AL 增强图像、HN 增强图像、Retinex-SSR 增强图像、Retinex-MSR 增强图像、ACE 增强图像、Laplus 算子增强图像、Log 增强图像、同态滤波增强图像、Water-Net 增强图像、UIEB 参考图像

从上面七张图中可以看到，综合来说，利用构建的 Water-Net 在各种类型情况下都能有效地去除了水下图像上雾霾的同时对图像的色度、对比度进行了修复，而竞争对比方法可能会引入意外颜色（例如，Retinex-SSR、Retinex-MS、同态滤波）和伪影（例如，Retinex-SSR、Retinex-MS、Log），或者对输入几乎没有影响（例如，暗通道先验、Histogram Normalization、ACE、Laplus 算子）。此外，使用 Water-Net 得到的部分结果甚至实现了比相应参考图像更好的视觉质量（例如，更自然的外观和更好的细节）。我猜测这是因为感知损失优化的水网可以从大规模真实世界水下图像数据集中学习良好视觉质量的潜在属性。

5.2 定量分析

将 UIEB 用作训练的 800 张图像剔除后，剩余的 90 张作为前面说过的测试集 1 的一部分；然后使用训练好的模型，分别对测试集 1（90 张加上 60 张 challenge 图像）和训练集 2（RUIE 数据集的一部分）进行增强；最后用 UIQM 和 UCIQE 分别计算两个测试集原始图像、经过 Water-Net 和定性分析中使用到的一些算法增强后的平均分。

RUIE 是一个包含三种不同类水下图像色彩类型的图像：绿色、蓝色、蓝绿色，由于 RUIE 是用水下机器人拍摄的连续的图像，所以为了是数据集场景不过于单一，我对原数据集进行了删减，从三种不同的图像数据集中分别挑选 20 张图像，并保证这 20 张图像的场景无重复。

增强后两个测试集图像经过 UIQM 和 UCIQE 计算得到的评估结果如表 2、3 所示：

	UIQM	UCIQE
RAW	2.8486	0.5130
DCP	2.8527	0.5826
自动色阶	5.1354	0.7385
Histogram Normalization	3.7965	0.5870
Retinex-SSR	3.2361	0.3676
Retinex-MSR	3.2952	0.4184
ACE	5.0091	0.6651
拉普拉斯算子	3.4701	0.5659
Log	1.8444	0.3141
同态滤波	4.0219	0.5672
Water-Net	4.3548	0.6080

表 2: UIEB-150 经过不同增强算法后的 UIEB 和 UCIQE 评估

从评分结果中可以很清楚的看到，经 Water-Net 增强后的的平均得分的确得到了极大提升，但自

	UIQM	UCIQE
RAW	1.427	0.4237
DCP	1.7395	0.5128
自动色阶	5.5147	0.7257
Histogram Normalization	4.3535	0.5690
Retinex-SSR	3.7392	0.4558
Retinex-MSR	3.8958	0.4889
ACE	5.3534	0.6599
拉普拉斯算子	2.0913	0.4587
Log	2.0854	0.3524
同态滤波	2.9975	0.5094
Water-Net	4.7895	0.5699

表 3: RUIE-60 经过不同增强算法后的 UIEB 和 UCIQE 评估

动色阶和 ACE 算法的评分高过了 Water-Net，看似效果更好，但我经过将三种方法得到的图像与原始图像进行对比，实际上是 Water-Net 效果更好。

对此我推断有两个原因：

一是 UIEB 和 UCIQE 可以很好的对具有水下特征的水下图像质量进行评估，但是如果是经过一定算法处理过后的水下图像，他可能已经失去了水下环境所导致的那些特征，甚至是算法彻底改变了一些特征（比如使对比度暴增）以至于图像都失真了，这个时候用肉眼都可以看出增强后的图像效果不行，而 UIQM 和 UCIQE 的评价结果却很高，这是极其不准确的。

二是对同一片海域拍摄的同类型的图像使用相同的 UIQM 和 UCIQE 参数是比较好的，但是对不同种类特征的图像，由于其色度、对比度、甚至是拍摄设备都不同的图像，使用相同的参数是不合理的。

6 总结与展望

在本次复现实验中，我根据论文 An Underwater Image Enhancement Benchmark Dataset and Beyond 中的思路，总结整理作者构建水下基准图像数据集的方法，对论文中提出的 Water-Net 神经网络、水下图像评估算法 UIQM 和 UICQE、相关图像处理的基础算法等进行了学习复现。

复现的 Water-Net 水图像增强网络，通过使用论文作者整理的 UIEB 水下图像基准数据集进行训练，得到的模型对其他水下图像也有非常不错的效果。并且通过最后的测试对比试验也可以看到，Water-Net 无论是定性还是定量上都取得了最优的性能。

但是需要思考的是，UIEB 数据集中的参考图像并不是真正真实的图像，而是通过人为评选的方式选出来的，这种方法得到的参考图像可能非常符合人眼视觉的一般感知，但是与真实情况的差距我们无从得知。作者也在文中说明，水下图像受到的背散射影响是很难完全消除，特别是对于远距离的背散射。就算是使用最先进的图像增强算法来处理原始水下图，在某些情况下，反向散射仍然不能完全消除。

同时，Water-Net 网络实际上只对水下环境对图像造成颜色、对比度差异进行了增强，但是图像的清晰度没有得到较大的提升，甚至有些图像警告过增强后更加模糊了。而且由于我本人暂时还没有系统的学习图形学相关知识，在对 UIQM 和 UCIQE 进行复现时，不是很清楚它文章中所说的用这样方式的原因，其中的一些图形学相关概念也不是很了解，只是简单的根据文章作者的公式进行了复

现，这种方式不能够很好的帮助我之后的图像处理学习。

此外，由于 UIEB 数据集收集来自于不同的场景，使用 UIQM 和 UCIQE 进行整体评估时效果飘忽不定，希望通过之后的探索与学习，能够找到一种不需要特意调参的、针对所有类型水下图像都公平的评估算法。

针对以上问题，在未来的学习过程中，一方面我会更多的去关注一下图像清晰度提升、去雾等方面算法，试着将其与 Water-Net 相结合，进一步提升网络性能；另一方面，我会进一步学习图形学相关知识，掌握图像处理相关概念，为之后的水下机器人和高空气球项目打好基础。

最后，我也尝试对神经网络进行优化，试想的是将网络再加一个由 ace 增强得到的图像作为输入，但是实现以后效果反而更差了，这其中具体的情况我还没有摸清，之后的学习过程中有时间也会对这部分进行思考探索。

参考文献

- [1] CHONG L. An underwater image enhancement benchmark dataset and beyond[J]. IEEE Transactions on Image Processing, 2019, 29: 4376-4389.
- [2] PENG Y T, COSMAN P C. Underwater Image Restoration Based on Image Blurriness and Light Absorption[J]. IEEE Transactions on Image Processing, 2017, 26(4): 1579-1594. DOI: 10.1109/TIP.2017.2663846.
- [3] 代成刚; 林明星; 王震; 张东; 管志光. 基于亮通道色彩补偿与融合的水下图像增强 Absorption[J]. 光学学报, 2015, 38: 86-95.
- [4] NARASIMHAN S, NAYAR S. Contrast restoration of weather degraded images[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2003, 25(6): 713-724. DOI: 10.1109/TPAMI.2003.1201821.
- [5] ANCUTI C, ANCUTI C O, HABER T, et al. Enhancing underwater images and videos by fusion[J]. 2012 IEEE Conference on Computer Vision and Pattern Recognition, 2012: 81-88.
- [6] FU X, ZHUANG P, HUANG Y, et al. A retinex-based enhancing approach for single underwater image [J], 2014: 4572-4576. DOI: 10.1109/ICIP.2014.7025927.
- [7] HE K, SUN J, TANG X. Single Image Haze Removal Using Dark Channel Prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(12): 2341-2353. DOI: 10.1109/TPAMI.2010.168.
- [8] DREWS P L, NASCIMENTO E R, BOTELHO S S, et al. Underwater Depth Estimation and Image Restoration Based on Single Images[J]. IEEE Computer Graphics and Applications, 2016, 36(2): 24-35. DOI: 10.1109/MCG.2016.26.
- [9] ANWAR S, LI C. Diving deeper into underwater image enhancement: A survey[J/OL]. Signal Processing: Image Communication, 2020, 89: 115978. <https://www.sciencedirect.com/science/article/pii/S0923596520301478>. DOI: <https://doi.org/10.1016/j.image.2020.115978>.

- [10] HORÉ A, ZIOU D. Image Quality Metrics: PSNR vs. SSIM[J], 2010: 2366-2369. DOI: 10.1109/ICPR.2010.579.
- [11] WANG Z, BOVIK A, SHEIKH H, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612. DOI: 10.1109/TIP.2003.819861.
- [12] N. HAUTIERE J P T. Blind contrast enhancement assessment by gradient ratioing at visible edges[J]. Image Anal. Stereol, 2008: 87-95.
- [13] YANG M, SOWMYA A. An Underwater Color Image Quality Evaluation Metric[J]. IEEE Transactions on Image Processing, 2015, 24(12): 6062-6071. DOI: 10.1109/TIP.2015.2491020.
- [14] PANETTA K, GAO C, AGAIAN S. Human-Visual-System-Inspired Underwater Image Quality Measures[J]. IEEE Journal of Oceanic Engineering, 2016, 41(3): 541-551. DOI: 10.1109/JOE.2015.2469915.
- [15] 徐岩; 曾祥波. 基于红色暗通道先验和逆滤波的水下图像复原[J]. 激光与光电子学进展, 2018, 55(02): 221-228.
- [16] 代成刚; 林明星; 王震; 张东; 管志光. 基于亮通道色彩补偿与融合的水下图像增强[J]. 光学学报, 2018, 38(11): 86-95.
- [17] LIU K, LIANG Y. Underwater image enhancement method based on adaptive attenuation-curve prior [J]. Optics express, 2021, 29(7): 10321-10345.
- [18] PANETTA K, AGAIAN S, ZHOU Y, et al. Parameterized logarithmic framework for image enhancement[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 2010, 41(2): 460-473.